# $\label{eq:problem} Pflichtenheft\\ Helmholtz-Zentrum\ Dresden-Rossendorf$

## Digital Signal Processing

Eine Cuda Implementierung des Levenberg-Marquardt Algorithmus zu Auswertung von Messdaten für die Positron Annihilations Spektroskopie.

Fabian Jung Mat.Nr.: 3755341 Diplom Informatik Nico Wehmeyer Mat.Nr.: 3658043 Diplom Informatik Richard Pfeifer Mat.Nr.: 2922220 Promotion Physik

### Inhaltsverzeichnis

#### 1 Optimierungsalgorithmus

#### • Aufgabe

Der Algorithmus soll die gemessenen Daten näherungsweise als Funktion interpretieren. (Die Daten sind gleichmäßig über die Zeit verteilt und repräsentieren die Funktionswerte.)

Anschließend sollen der Anfangs-, End- und Maximalwert der Funktion bestimmt werden.

#### • Implementierungsschritte

- Levenberg-Marquardt-Algorithmus
- double zu short int konvertieren (betrifft Messdaten)
- kernel-Methode (statt main)
- Speicher der Grafikkarte nutzen (statt malloc)
- Cuda Array nutzen (statt Array)
- Berechnung von Anfangs- und Endfunktionswerten (ggf. mitteln)
- Rückgabe der Ergebnisdaten
- ggf. kernel zu sub-kernel parallelisieren
- ggf. andere Fit-Funktion (z. B.  $e^{-x^2}$  mit entsprechenden Parametern) verwenden oder Daten vor Bestimmung der quadratischen Funktion trimmen

#### 2 Speichertransfer zwischen Host und Device

#### 2.1 Grobgliederung

Die Eingangsdaten werden aus einem Ringpuffer gelesen. Die Ergebnisse werden zunächst in einem Ringpuffer zwischengespeichert und dann in eine Datei geschrieben. Jeder Node erhält seinen eigenen Thread, der die Daten aus dem Eingangspuffer auf die Grafikkarte kopieren. Das Schreiben in die Datei wird ebenfalls von einem eigenen Thread erledigt. Damit es nicht zu Lese- oder Schreibkonflikten kommt, werden die Puffer durch Semaphoren geschützt. Um die einzelnen Nodes zu verwalten wird eine Klasse implementiert, deren Objekte jeweils einen der 4 Nodes der GPU verwalten.

#### 2.2 Aufgaben

- Initialisierungscode schreiben
  - Auslesen der Systemdetails mit cudaDeviceProps
  - Objekte für jeden Node erstellen
  - die einzelnen Threads starten
- Node Klasse
  - Attribute
    - \* Device Pointer
    - \* Referenz auf Ringpuffer für Eingang
    - \* Referenz auf Ringpuffer für Ausgang
    - \* finish
      - · Variable die vom Host gesetzt werden kann um anzuzeigen, dass keine neuen Daten mehr folgen
  - Konstruktor/Destruktor
  - Methoden
    - \* stop (public)
      - · Host beendet den Thread evt. auch im Destruktor implementiert
    - \* run (public)
      - · Wird als eigener Thread gestartet
    - \* copyToDevice (private)
    - \* getResults (private)
- Speichertransfer Host -> Device
  - In Methode copyToDevice
  - Textur Referenz anlegen (im File scope)
  - Texturobjekt initialisieren
  - Daten in Textur kopieren
  - Anschließend Kernel starten

- Speichertransfer Device -> Host
  - Ende des Kernels abwarten
  - cudaMemcopy der Daten auf den Stack
  - Einfügen in Ausgangspuffer
- Ausgangspuffer
  - Attribute
    - $*\ of stream\ output File$
    - \* vector finished
      - · Zeigt für jeden Node an, ob dieser noch weitere Daten liefert
  - Initialisierung
    - \* Datei öffnen
    - \* finished mit false füllen
  - Destruktor
    - \* Datei schließen
  - Empty
    - \* Wird in eigenen Thread gestartet
    - \* Läuft, solange mindestens einer der Werte aus dem vector finished false
    - \* Schreibt die Ergebnisse unsortiert in Datei
    - \* Sortierte Ausgabe mögliche Erweiterung
  - Write
    - \* Id und Datenstruct in Queue schreiben
  - finished
    - \* setzt ein Bit für einen Node in finished auf true

#### 3 Host

#### 3.1 Anforderung

- Auf externem Speicher vorliegende Daten sollen in einen Puffer geladen werden. Zwecks Weiterverarbeitung muss eine Schnittstelle bereitgestellt werden, um diese Daten effektiv aus dem Puffer in den Graphikkartenspeicher zu transportieren.
- Das Auslesen aus dem Puffer erfolgt durch mehrere Threads. Alle Operationen auf dem Puffer müssen demnach threadsafe gestaltet sein.

#### 3.2 Hauptbestandteile

Die Anforderungen sind typisch für ein Erzeuger-Verbraucher-Problem. Dieses wird durch folgende Komponenten gelöst:

#### 3.2.1 Ringpuffer-Klasse

Der Ringpuffer wird durch Erzeuger und Verbraucher gefüllt/geleert. Die Puffergröße ist fix. Threadsicherheit wird mittels Semaphoren in die Ringpufferklasse implementiert. Da momentan POSIX-Plattformen als Ziel genannt sind, wird semaphore.h dafür genutzt.

```
template <class type>
2 class Ringbuffer() {
3 private:
      sem_t mtx;
      sem_t full, empty;
      Ringbuffer(size_t bSize);
      ~Ringbuffer();
      type* reserveHead(unsigned int count);
9
      int freeHead(type* data, unsigned int count);
10
      type* reserveTail(unsigned int count);
11
      int freeTail(type* gpu_data, unsigned int count);
12
13 }
```

- Der Zustand voll / leer wird über die Semaphore sem\_w (Anfangszustand bSize), sem\_r (Anfangszustand 0) festgestellt.
- Die Funktion write blockiert bei vollem Puffer um ein Verlust an Messdaten entgegenzuwirken. Für späteres Lesen eines Datenstroms direkt vom Messgerät kann auch nichtblockierendes Schreiben in den Puffer mit entsprechendem Überlauf implementiert werden.
- readToCUDA kopiert die Daten vom Tail des Puffers nach \*gpu\_data. Die Verantwortlichkeit für cudaSetDevice(deviceId) ist noch zu klären. Der Kopiervorgang kann nicht asynchron ablaufen, um den Speicher im Puffer sicher freigeben zu können.
- readToHost kopiert die Daten vom Tail des Puffers an eine Hostspeicheradresse. Dies dient zum Testen der CPU-Variante des Auswertealgorithmus.

• size in write, readToHost und readToCUDA gibt jeweils die Anzahl der auszutauschenden Waveforms vom Datentyp wform an.

#### 3 Semaphoren:

- sem\_mtx für exklusiven Zugriff auf Speicher
- sem\_r um Lesezugriff bei leerem Puffer zu regeln
- sem\_w um Schreibzugriff bei vollem Puffer zu regeln

Der Datentyp wform ist zunächst fix. In einer zweiten Version wird er per Template implementiert.

#### 3.2.2 Erzeuger-Klasse

Verantwortlich für das Einlesen der Daten aus einer Verzeichnisstruktur in den Puffer. Die Waveforms aus den beiden Kanälen werden aufgetrennt in zwei Waveforms. Dazu wird ein kleiner interner Puffer verwendet. Der Erzeuger versucht zu schreiben, solange er Daten liefern kann. Der tatsächliche Schreibvorgang wird über das Semaphore sem\_winnerhalb der Ringpufferklasse gesteuert.

Die sample-Daten sind laut Code vom Typ short int. Damit ergibt sich für wform

typedef short int wform[nSample]

#### 3.2.3 Verbraucher

Der Verbraucher wird im Teil "Speichertransfer" beschrieben. Das Semaphore sem\_r regelt den Lesezugriff innerhalb der Ringpufferklasse.

Der Verbraucher stellt über entsprechendes mapping sicher, dass die Datenreihenfolge bekannt bleibt, um die Ergebnisse den Eingangsdaten zuordnen zu können.

#### 3.3 Tasks

- Erzeugerklasse: Lesen der Messdaten mit root-Verzeichnis der Daten als Eingabewert
- erwartete Ordnung der Messdaten nach Einlesen im Puffer beschreiben
- Ringpuffer initialisieren
  - Speicherreservierung
  - Semaphoren: sem\_mtx, sem\_w, sem\_r
- Ringpuffer: write
- ullet Ringpuffer: readToHost
- Ringpuffer: readToCUDA
- Vergleich der Ergebnisse CPU vs GPU-Auswertung
- Skalierung
- Template-version des Ringpuffers